



DATAFEST 2023

Не бойтесь выкладывать свои
разработки в open-source -
даже если кажется, что они не
закончены

ДОКЛАДЧИК: САРАФАНОВ МИХАИЛ
SENIOR DATA SCIENTIST, WIREDHUT



ИТМО



Что ждать от доклада



Хочется, чтобы слушатели:

- С шутками и хорошим настроением начали (или продолжили) секцию датафеста посвященную open-source; 😜
- Послушали про то как другие делают кривые open-source продукты и ими все равно пользуются;
- Зарядились желанием делиться собственными разработками

Если чуть серьезней и предметно по структуре:

- Немного про то кто я (докладчик) такой и на примере каких трех малаеньких проектов буду строить рассказ; 😎
- Составляющие почти идеального open-source продукта в вакууме;
- Немного информации про каждый из трех open-source проектов: что делает, какими силами разивался и развивается;
- Что сделано в этих проектах хорошо, а что ну... плохо;
- Почему считаю, что каждый из них по своему удался



Чувствуйте себя как дома

*тут не будет душных слайдов с теорией, только яркие примеры из личного опыта, и советы, которые (по крайней мере для меня) работают



Прежде чем начать



- Это я, типичный data scientist, которому посчастливилось принять участие в разработке нескольких open-source продуктов



Государственный Гидрологический Институт (2019-2020)

Обработка спутниковых снимков, разработка ML моделей для прогнозирования уровня воды в реках



Университет ИТМО (2020-2022)

Разработка AutoML инструментов. Например, фреймворк FEDOT




Wiredhut Oy (2022...)

Разработка прогностических моделей перемещения людей по человеческим городам и пригородам, проектирование и реализация систем для обработки данных получаемых с различных сенсоров


1

ИТМО



SSGP-toolbox

2




Lines Ranking

Qgis Lines ranking.plugin

3

ИТМО



pytsbe



Самая самая главная цель

*Показать, что не всегда open-source
проекты должны быть большими и
качественными, иногда они просто
должны быть*

© Джейсон Стетхем



Составляющие крутого open-source

- **Большое сообщество пользователей и контрибьюторов**
- **Архитектура**, которая позволяет быстро расширять функциональность библиотеки. "Красивый" код как таковой
- **Тесты** - достаточное покрытие кода тестами
- **CI/CD** - настроенные автоматические помощники (линтер, автоматический запуск тестов и т.д.)
- **Development guideline** - выстроенный среди maintainer'ов прозрачный процесс утверждения задачи, выполнения и доработки, а также включения изменений в основной код проекта
- **Простой процесс установки** (оба)
- **Простой интерфейс** (насколько это возможно) для запуска open-source модуля
- **Понятная документация** как для пользователей, так и для разработчиков. Доходчивые примеры и пояснения, статьи по теме
- **Сопровождение** - регулярное улучшение библиотеки и поддержка пользователей
- **Много звезд на гитхабе**



Большое сообщество пользователей и контрибьюторов




Свежо, интересно, вызывает доверие

Used by 30




Contributors 27



+ 16 contributors

Languages



Страшно и ненадежно

Readme

7 stars

2 watching

0 forks

Releases

No releases published

Create a new release

Packages


No packages published

Publish your first package



Архитектура


Разнесенные по разным модулям файлы могут изменяться одновременно, что позволяет работать нескольким разработчикам над проектом одновременно. Всегда стоит ожидать, что кто-угодно может захотеть исправить или дополнить какой-угодно модуль, - и эту возможность надо предоставить!



Тесты

В процессе разработки (особенно когда разработчиков много) неизбежно появляются ошибки.

Установить наличие ошибки помогают тесты: если тесты выполняются корректно изменения могут быть интегрированы в master / main ветку. Если хотя бы один не выполняется – контрибьютору следует внести исправления




CI/CD и Development guideline

Что можно автоматизировать и делать без участия людей - лучше автоматизировать.

Для остальных вещей пишется руководство

© Тоже Джейсон Стетхем



Простота в установке и использовании. Документация



"Интуитивно понятная архитектура"


Кто угодно



Сопровождение


Jan 12, 2020 – Apr 30, 2023

Contributions to master, excluding merge commits and bot accounts



Feb 16, 2020 – Apr 30, 2023

Contributions to master, excluding merge commits and bot accounts



Запомним критерии

*Итак, мы будем использовать
вышеперечисленные 10 критериев для
оценки крутизны open-source библиотек.*


"Всосали?"

© А так уже говорила моя учительница по математике



Пример "идеального" open-source




Большое сообщество пользователей и контрибуторов	✓
Архитектура	✓
Тесты	✓
CI/CD	✓
Development guideline	✓
Простой процесс установки	✓
Простой интерфейс	✓
Понятная документация	✓
Сопровождение	✓
Много звезд на гитхабе	✓




SSGP-toolbox



Библиотека для заполнения пропусков в спутниковых снимках при помощи машинного обучения





Что не так

Большое сообщество пользователей и контрибьюторов	X
Архитектура	✓ X
Тесты	X
CI/CD	X
Development guideline	X
Простой процесс установки	X
Простой интерфейс	✓ X
Понятная документация	✓ X
Сопровождение	✓ X
Много звезд на гитхабе	✓




SSGP-toolbox
когда я его
проектировал

SSGP-toolbox
на момент "выпуска"
в 2020

SSGP-toolbox
когда я смотрю на него
спустя 2 года
(код не изменился за это время)

Документация в jupyter notebooks, никаких билдов на readthedocs и так далее, PEP8? - просто забудьте про стандарты - там их нету, декомпозиции кода почти нет, все держится на if else.





Почему это все таки хороший модуль

Screenshot of the GitHub repository page for Dreamlone / SSGP-toolbox. The repository has 182 commits, 2 branches, and 0 tags. The master branch is selected. Recent commits include 'Dreamlone float compare fix' and 'Comparison update comparison docs'. The repository has 25 stars, 7 forks, and 1 watching.

Commit	Description	Date
Dreamlone float compare fix		d7621b5 on Dec 23, 2021
Comparison	update comparison docs	3 years ago
Notebooks	Update documentation	3 years ago
SSGPToolbox	float compare fix	2 years ago
Samples	gapfiller core refactor	3 years ago
Supplementary	Parallel mode added	3 years ago
LICENSE	Initial commit	3 years ago
README.md	update docs	3 years ago
setup.py	docs refactor p.1	3 years ago

На репозиторий ссылается статья в Q1 журнале. На репозитории аж 25 звезд и 35+ цитирований у статьи


Периодически (раз в месяц) мне на почту пишут пользователи с вопросами. Пользователи - такие же исследователи и инженеры в области дистанционного зондирования Земли - целевая аудитория данного модуля. Им действительно регулярно пользуются

Screenshot of the journal article details page. The article is titled 'A Machine Learning Approach for Remote Sensing Data Gap-Filling with Open-Source Implementation: An Example Regarding Land Surface Temperature, Surface Albedo and NDVI'. It was published in 'Remote Sensing' (Volume 12, Issue 23, Pages 3865) by MDPI on November 25, 2020. The authors are Mikhail Sarafanov, Eduard Kazakov, Nikolay O. Nikitin, Anna V. Kalyuzhnaya. The article has 35 citations. The abstract discusses the use of machine learning algorithms for filling gaps in remote sensing time-series data based on spatial relationships between pixels and temporal dynamics of each pixel value.





QGIS Lines ranking plugin

QGIS - open-source
приложение для
геоинформационного
анализа




Lines ranking - позволяет
ранжировать сегменты
векторного слоя



Что не так

Большое сообщество пользователей и контрибьюторов	X
Архитектура	X
Тесты	X
CI/CD	X
Development guideline	X
Простой процесс установки	✓ X
Простой интерфейс	✓ ✓
Понятная документация	X
Сопровождение	✓ X
Много звезд на гитхабе	✓ X



Lines Ranking

И что тогда на нас нашло...

Какие утилиты для версионирования кода вы используете



Код организован по принципу "как пришлось" и распихан на три большие (здоровенные) функции и обвязки для интеграции с QGIS. Тестов нет, ровно как и документации



Почему это все таки хороший модуль

QGIS Python Plugins Repository

[Get unlimited access](#)

★★★★★ (3) votes


Plugin for ranking lines features based on the position of starting point

About Details Versions

Version	Experimental	Minimum QGIS version	Downloads	Uploaded by	Date
1.0	no	3.14.0	2001	chrislisbon	30 июл. 2020 г., 12:52 GMT+3

Потому что им пользуются, и иногда даже скачивают.
Пользователи пишут вопросы на почту.

А ещё мы научились писать плагины для QGIS и статьи на хабр и TowardsDataScience на интересные нам темы и сделали первые шаги в продвижении open-source продуктов



Lines Ranking

The Algorithm for Ranking the Segments of the River Network for Geographic Information Analysis Based on Graphs

Introduction

The topic of this article is the application of information technologies in environmental science, namely, in hydrology. Below is a description of the algorithm for ranking rivers and the plugin we implemented for the open-source geographic information system QGIS.

An important aspect of hydrological surveys is not only the collection of information received from research expeditions and automatic devices but also the analysis of all the obtained data, including the use of GIS (geoinformation systems). However, exploration of the spatial structure of hydrological systems can be difficult due to a large amount of data. In such cases, we cannot do research without using additional tools that allow us to automate the process.

Visualization plays an important role when working with spatial data. Correct visual representation of the results of the analysis helps to better understand the structure of spatial objects and to know something new. For the image of rivers in classical cartography, the following method is used: rivers are represented as a solid line with a gradual thickening (depending on the number of tributaries that flow into the river) from the source to the mouth of the river. Moreover, segments of the river network often need to be ranked by the degree of distance from the source. This type of information is important not only for visualization, but also for a more complete perception of the data structure, its spatial distribution, and subsequent processing.

The problem of ranking rivers can be illustrated as follows (Fig. 1):




Figure 1. Ranking rivers task, numbers indicate the attribute assigned to each segment of the river network for the total number of tributaries flowing in

Get unlimited access



Mikhail Sarafanov
195 Followers
ML engineer

Edit profile

More from Medium



Alexander Ng... in Level Up Co...
Why I Keep Failing Candidates During Google Interviews...




Matt Chap... in Towards Data Sc...
The Portfolio that Got Me a Data Scientist Job



Timothy Mu... in Better Program...
How To Build Your Own Custom ChatGPT With Custom Knowledge Base



Erdogan Tas... in Towards Data ...
From Data to Clusters; When is Your Clustering Good Enough?








20

pytsbe


Open-source модуль для бенчмаркинга
алгоритмов прогнозирования временных
рядов

Позволяет запускать несколько
алгоритмов прогнозирования временных
рядов, измеряет различные метрики и
ГОТОВИТ ВИЗУАЛИЗАЦИИ И СВОДНЫЕ ТАБЛИЦЫ



Что не так

pytsbe



Большое сообщество пользователей и контрибьюторов	X
Архитектура	✓
Тесты	✓
CI/CD	X
Development guideline	✓
Простой процесс установки	✓ X
Простой интерфейс	✓
Понятная документация	✓
Сопровождение	✓ X
Много звезд на гитхабе	✓




Документация держится просто в markdown файлах. Модуль так и не "выставлен" в PyPI, половина заявленной функциональности не реализована



Почему это все таки хороший модуль

pytsbe



The screenshot shows the GitHub repository for pytsbe. It includes:

- Description:** A brief overview of the repository as a time series forecasting module.
- Univariate time series:** Includes a list of libraries and models like ARIMA, Exponential Smoothing, and TBATS.
- Datasets:** Lists datasets such as FRED, TSP, and Smart.
- And visualizations:** Three small plots showing time series data.
- Multivariate time series:** Includes a list of libraries and models like ETS and SARIMAX.
- Documentation:** A link to the README for more details.
- Benchmark:** A link to a benchmark section.

- Документация (и README в том числе) на самом деле не так плоха
- Руководство для разработчиков "прошло проверку" - без моей помощи разработчики смогли включить дополнительный субмодуль в библиотеку
- Архитектура позволяет быстро и относительно безболезненно расширять функциональность
- Тесты "не хрупкие" и легко модифицируются



- Модуль уже выполнил свое предназначение - позволил провести эксперименты с алгоритмами прогнозирования временных рядов для внутренних исследований лаборатории
- Представляет собой своеобразное "наследие" после моего ухода из команды. Наработки и уже написанные обвязки не пропали, а существуют в виде изолированного модуля и при необходимости с полуоткрытым лицом могут быть запущены бывшими коллегами



Заключение

Иногда страшно выкладывать свои разработки в open-source потому что они кажутся незаконченными, слишком маленькими и неказистыми

Кажется, что open-source проекты должны быть большими, с хорошей документацией и активным сообществом

Кажется, что open-source проекты будут отнимать у вас много времени на сопровождение и не смогут должным образом развиваться

Но иногда open-source решениям стоит "быть" просто потому что они сделаны с любовью ❤️

*надеюсь, вам понравился рассказ про некоторые из таких

На этом всё





DATAFEST 2023

Спасибо за внимание!

mik.sarafanov@gmail.com